EM Algorithm

EXPECTATION & MAXIMIZATION

응용수학과 최우빈

EM 알고리즘

관측되지 않는 잠재변수에 의존하는 확률 모델에서 maximum likelihood 나 maximum a posteriori(MAP)을 갖는 매개변수를 찾는 반복적인 알고리즘

- 1) 초기 추측 Θ(0) = (μ0 , μ0 , var0 , var0, p)
- 2) E step : 매개변수에 관한 추정 값으로 log likelihood의 기대 값 계산
- 3)M step : 기대 값을 최대화하는 변수 값 계산

$$(X,Z)$$
의 확률 분표): $L(\boldsymbol{\theta};\mathbf{X},\mathbf{Z})=p(\mathbf{X},\mathbf{Z}|\boldsymbol{\theta})$

X : 관측 가능 확률변수 Maximum Likelihood 함수 : $L(m{ heta}; \mathbf{X}) = p(\mathbf{X}|m{ heta}) = \sum_{=}^{n} p(\mathbf{X}, \mathbf{Z}|m{ heta})$ Z : 관측 불가능 확률변수

E - step: Θ(t): 현재 Θ, Θ: 새로운 Θ, Q: likelihood의 기대 값

$$Q(m{ heta}|m{ heta}^{(t)}) = \mathrm{E}_{\mathbf{Z}|\mathbf{X},m{ heta}^{(t)}}[\log L(m{ heta};\mathbf{X},\mathbf{Z})] = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X},m{ heta}^{(t)}) \log L(m{ heta};\mathbf{X},\mathbf{Z})$$

M – step : Q 최대화 Θ(t+1) : 새로운 매개변수

$$oldsymbol{ heta}^{(t+1)} = rg\max_{oldsymbol{ heta}} Q(oldsymbol{ heta}|oldsymbol{ heta}^{(t)})$$

n번 실행 : log likelihood 수렴

$$\Theta = \Theta(t)$$

$$\Theta(t) = \Theta(0)$$

$$E - step$$

$$\Theta(t) = \Theta(t+1) = \Theta$$

$$\Theta(t) = \Theta(t+1)$$

Example 7.6.15

Table 7.1 Heights and weights for Example 7.6.15. The missing values are given random variable names.

Height	Weight
72	197
70	204
73	208
68	$X_{4,2}$
65	$X_{4,2} \\ X_{5,2}$
$X_{6,1}$	170

$$\theta^{(0)} = (\mu_1^{(0)}, \, \mu_2^{(0)}, \, \sigma_1^{2(0)}, \, \sigma_2^{2(0)}, \, \rho^{(0)}) = (69.60, \, 194.75, \, 2.87, \, 14.82, \, 0.1764).$$

$$\theta^{(32)} = (68.86, 189.71, 3.15, 15.03, 0.8965)$$


with log-likelihood -29.66 .

```
Gauss_dist.m: function [ y ] = gauss_dist(x,mu,var)
% GAUSS_DIST function for gaussian distribution
y=(1/(sqrt(2*pi*var)))*exp((-(x-mu).^2)/(2*var));
data=[-0.39 0.12 0.94 1.67 1.76 2.44 3.72 4.28 4.92 5.53,...
0.06 0.48 1.01 1.68 1.80 3.25 4.12 4.60 5.28 6.22];
```

% 초기 추측

```
pie(1)=0.5;
mu1(1)=data(temp(1)); % height 초기 평균
mu2(1)=data(temp(2)); % weight 초기 평균
var1(1)=var(data); % height 초기 분산
var2(1)=var(data); % weight 초기 분산
```


temp=randperm(length(data));



```
for i = 1:50 % 최대 50회 연산
```

```
% E - step : 매개변수의 추정 값으로 log likelihood 의 기대 값 계산
Qq1=gauss_dist(data,mu1(i),var1(i));
Qq2=gauss_dist(data.mu2(i),var2(i));
Log_likelihood(i)=sum(log(((1-pie(i))*Qq1) + (pie(i)*Qq2)));
% responsibility : posterior distribution
responsibilities(i,:)=(pie(i)+Qq2)./(((1-pie(i))+Qq1)+(pie(i)+Qq2));
% M - step : 기대 값을 최대화 하는 변수 값 계산, 미 때, 변수 값은 다음 E → step 의 추정 값으로 쓰임
mul(i+1)=sum((1-responsibilities(i,:)).*data)/sum(1-responsibilities(i,:));
mu2(i+1)=sum((responsibilities(i,:)).*data)/sum(responsibilities(i,:));
var1(i+1)=sum((1-responsibilities(i,:)).*((data-mu1(i)).^2))/sum(1-responsibilities(i,:));
yar2(i+1)=sum((responsibilities(i,:)).*((data-mu2(i)).^2))/sum(responsibilities(i,:));
pie(i+1)=sum(responsibilities(i,:))/length(data);
end
```

열1~8 -44.3359 -42.2845 -42.1152 -42.1016 -42.0847 -42.0605 -42.0240 -41.9665 열 9~16 -41.8719 -41.7103 -41.4328 -40.9907 -40.4395 -40.0043 -39.7723 -39.6262 열 17 ~ 24 -39.4936 -39.3597 -39.2297 -39.1152 -39.0274 -38.9706 -38.9396 -38.9248 열 25 ~ 32 -38.9183 -38.9155 -38.9143 -38.9138 -38.9135 <mark>-38.9134 -3</mark> 열 33 ~ 40 -38.9134 -38.9134 -38.9134 -38.9134 -38.9134 -38.9134 -38.9134 열 41 ~ 48 -38.9134 -38.9134 -38.9134 -38.9134 -38.9134 -38.9134 -38.9134 열 49 ~ 50 -38.9134 -38.9134



참고 문헌

- (1) https://en.wikipedia.org/wiki/Expectation%E2%80%93maximization_algorithm
- (2) https://kr.mathworks.com/matlabcentral/fileexchange/45817-expectation-maximization-algorithm-with-gaussian-mixture-model